



6. Auto Scaling




- 트래픽에 따라서 자동으로 서버의 개수를 조절해주는 기능
- 트래픽에 따라서 자동으로 EC2 인스턴스 개수를 조절해주는 기능

Auto Scaling의 필요성


- 서버로 들어오는 트래픽의 양은 고정되어 있지 않죠
- 갑자기 서버에 트래픽이 몰리게 되면, 빨간 점선으로 표시한 부분처럼 서버 용량 초과로 인해 서버에 장애가 발생
- 예) 명절 기차표 예약



- 이러한 상황을 방지하고자, 아래 그림처럼 서버의 최대 용량을 확 늘리는 방법을 사용
- 서버의 용량을 크게 유지해야 하기 때문에 이처럼 낭비되는 자원이 많이 생김



- 서비스를 안정적으로 제공하면서 낭비되는 자원이 없도록 비용 효율적으로 하기 위해서 등장한 것이 바로 **Auto Scaling**




- 실제 트래픽과 거의 유사한 수준으로 서버의 용량을 조절할 수 있음
- 트래픽이 늘어나도 서버의 용량이 자동으로 늘어남으로써 안정적으로 서비스를 제공
- Auto Scaling은 ELB와 함께 사용



2. Auto Scaling 기본 구조

Auto Scaling 기본 구조



- 클라이언트의 요청이 ELB로 들어오게 되고, 로드 밸런서에서 **ASG**라고 부르는 **Auto Scaling Group**으로 부하를 분산함
- ASG(**A**uto **S**caling **G**roup)은 **A**mazo**n** **M**achine **I**mage를 필요로 하며, **C**loud**W**atch라는 클라우드 모니터링 서비스를 사용해서 서버의 용량을 늘릴지 줄일지 결정
- ASG는 Auto Scaling되는 EC2 인스턴스들의 집합
- Cloud Watch라는 AWS의 서비스들을 모니터링하는 서비스와 연동함으로써 다양한 지표에 따라 인스턴스 개수를 조절할 수 있음
- Auto Scaling을 설정하기 위해서는 우리 말로 **시작 구성**이라고 부르는 **Launch Configuration**을 생성

3. 실습

- AMI 생성하기
- Auto Scaling Group 생성
- Auto Scaling 작동 테스트
- 블로그 접속해서 글쓰기